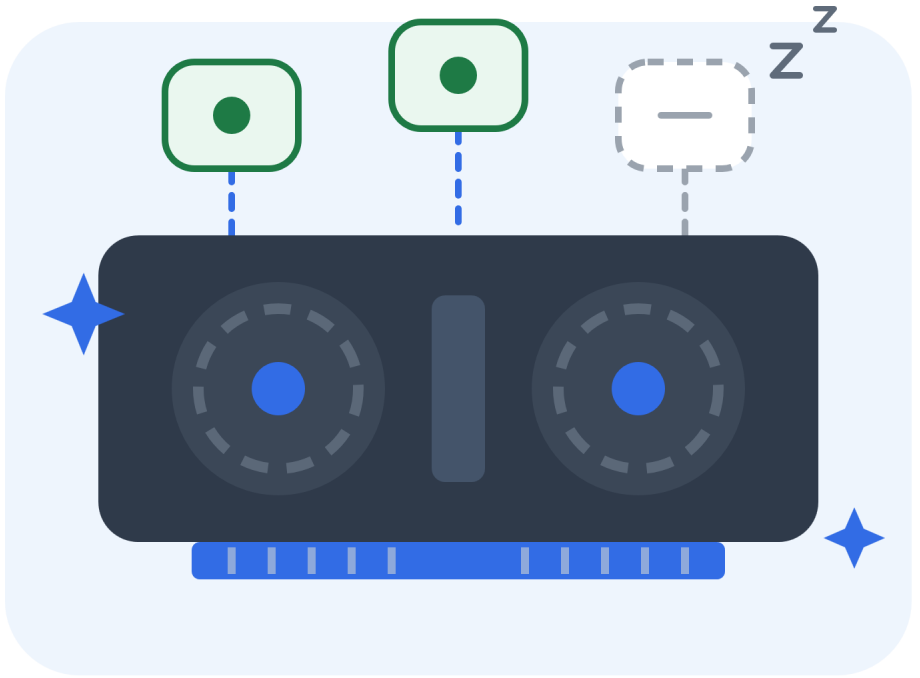
LINUX DAY 2026 · BENEVENTO · 24 OTTOBRE

KubeAI

L'AI libera e sostenibile, su Kubernetes

privata sostenibile aperta



Marco Cristofanilli

Maintainer KubeAI

Responsabile AI • Seeweb • regolo.ai

CHI SONO · UNA SLIDE, PROMESSO

Dal 1998 con Linux. Oggi è il mio lavoro.

1998

14 anni, il primo boot

Smanettare, rompere, reinstallare: così si impara.

OGGI

- Responsabile AI in Seeweb
- L'infrastruttura GPU e HPC di Seeweb e regolo.ai
- Maintainer di KubeAI

La passione di oggi può diventare il vostro lavoro di domani.

Marco Cristofanilli • Maintainer KubeAI

github.com/kubeai-project/kubeai

PRIMA LA DOMANDA GIUSTA

Che AI vogliamo?

Non basta che funzioni: deve rispettare persone, dati e pianeta.

Privata

I dati restano dove decidete voi.

Sostenibile

La GPU lavora solo quando serve.

Aperta

Codice libero: lo leggi, lo cambi, lo condividi.

Accessibile

Gira anche su un portatile: si impara facendo.

IL PROBLEMA

Orchestrare GPU e LLM: sei mal di testa

GPU care
Costano e consumano anche da ferme.

Modelli giganti
Decine di GB: ogni avvio è lento.

Hardware diverso
L4, H100, AMD, CPU: ognuna a modo suo.

Traffico a ondate
CPU e RAM non dicono quanto lavora un LLM.

Cache sprecata
Bilanciamento a caso: la KV cache va persa.

Mille API
Le app ne vogliono una: quella di OpenAI.

LA SOLUZIONE

Cosa risolve KubeAI, uno per uno

Scale da zero
Nessuna richiesta? Zero Pod, GPU libera.

Cache dei modelli
Volume condiviso, PVC o immagine OCI.

Resource profile
Scrivi nvidia-gpu-l4:1, al resto pensa lui.

Autoscaling vero
Scala sulle richieste e le mette in coda.

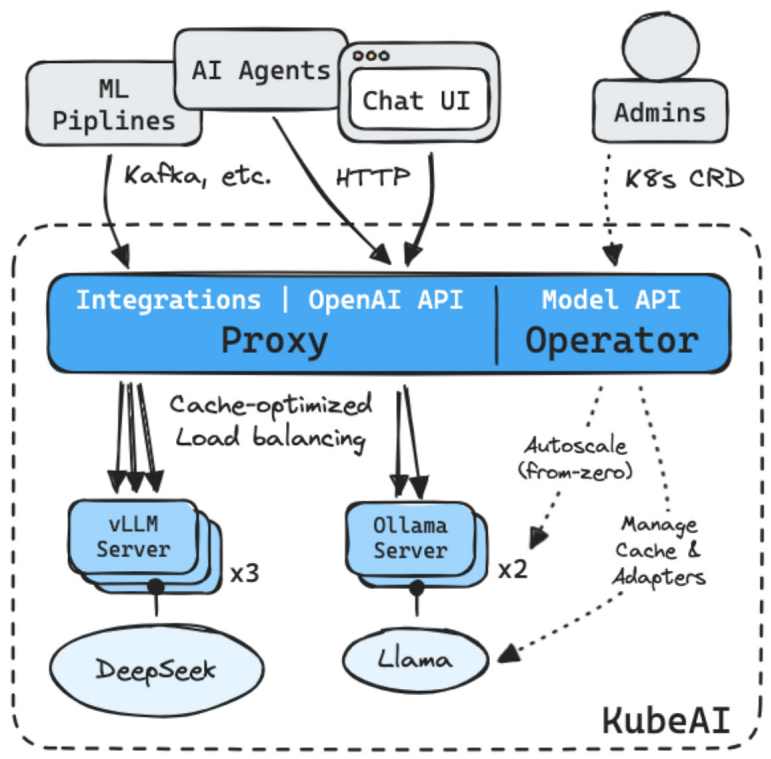
PrefixHash
Stesso prefisso, stessa replica: cache calda.

Un’unica API
Compatibile OpenAI, e ora anche Anthropic.

Un solo chart Helm **Zero dipendenze** **Licenza Apache 2.0**

DENTRO KUBEAI

Come funziona: il maître e lo chef



Proxy • il maître

API OpenAI, bilanciamento attento alla cache, coda durante lo scale da zero, retry.

Operator • lo chef

Gestisce i Pod dei motori, li accende da zero, prepara cache dei pesi e adattatori LoRA.

I motori • la cucina

vLLM, Ollama, SGLang, llama.cpp, Infinity, FasterWhisper.

Diagramma ufficiale: github.com/kubeai-project/kubeai, docs/diagrams • Apache 2.0

SOTTO IL COFANO

I motori: vLLM, SGLang, Ollama, llama.cpp

vLLM

GPU · PRODUZIONE

PagedAttention e batching continuo. Prefix caching e adattatori LoRA.

```
engine: VLLM
url: hf://…
```

SGLang

GPU · CACHE RADIX

RadixAttention riusa la KV cache tra richieste. Forte sugli output strutturati.

```
engine: SGLang
url: hf://…
```

Ollama

CPU O GPU · FACILE

Modelli pronti dal suo catalogo. Ideale per iniziare sul portatile.

```
engine: OLlama
url: ollama://…
```

llama.cpp

OVUNQUE · LEGGERO

C/C++ e modelli GGUF quantizzati: dal portatile all'edge, anche su GPU.

```
engine: LlamaCpp
url: hf://…GGUF
```

E non solo testo: Infinity • embedding e reranking · FasterWhisper • trascrizione audio

Decine di modelli già configurati nel catalogo: charts/models/values.yaml su GitHub

UN'UNICA API, TANTI MODELLI

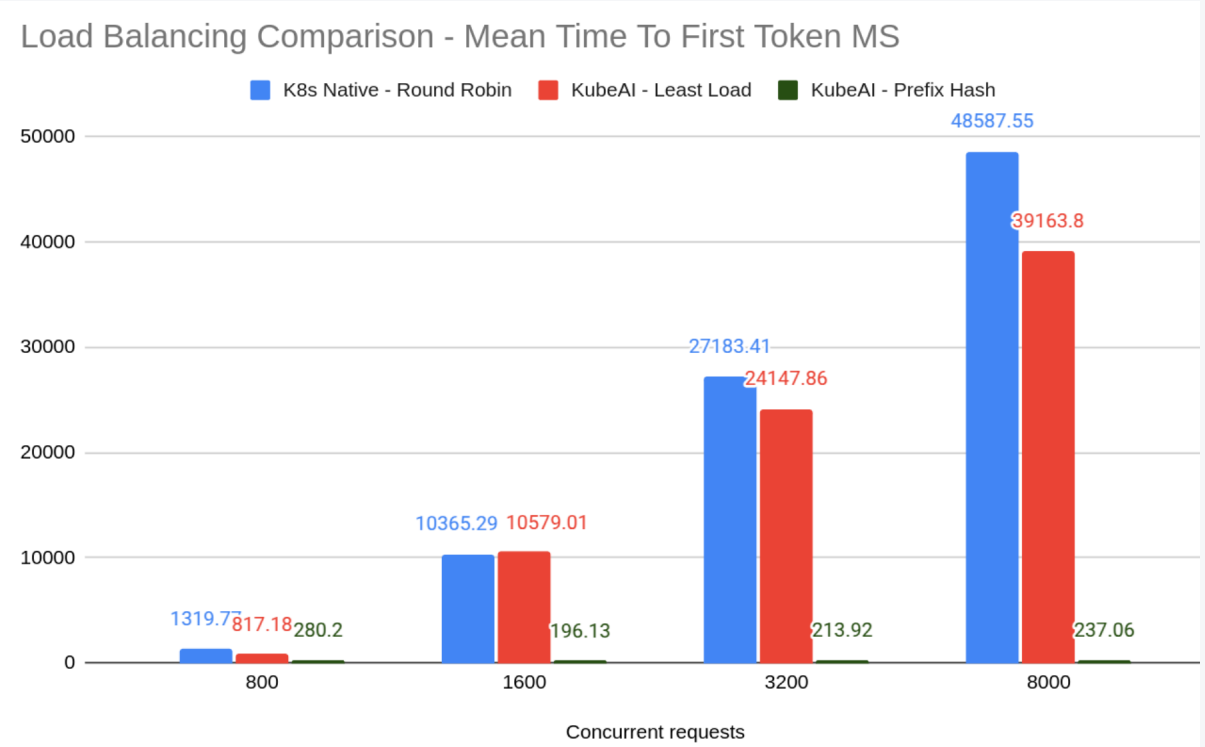
Gli endpoint: non solo LLM

Per cosa	Endpoint	Motori
Chat, anche con immagini	/openai/v1/chat/completions	vLLM, SGLang, Ollama, llama.cpp
Testo e Responses API	/openai/v1/completions /openai/v1/responses	gli stessi motori di testo
API in stile Anthropic	/v1/messages	modelli di testo
Embedding	/openai/v1/embeddings	Infinity, vLLM, Ollama, llama.cpp
Reranking	/v1/rerank	Infinity
Trascrizione audio	/openai/v1/audio/transcriptions	FasterWhisper
Decisioni System One	/v1/systemone	vLLM, SGLang, Ollama, llama.cpp
Elenco dei modelli	GET /v1/models	tutti

Tutti POST tranne l'elenco • base per gli SDK OpenAI: /openai/v1 • riferimento: docs/reference su GitHub

LA PROVA · BENCHMARK DEL PROGETTO

PrefixHash: la cache calda si vede



Con 8.000 richieste in parallelo, tempo medio al primo token:

48,6 s

bilanciamento nativo di Kubernetes

0,24 s

KubeAI con PrefixHash

Vale quando le richieste condividono l'inizio del prompt. Fonte: github.com/kubeai-project/kubeai, docs/benchmarks

UN ESEMPIO CHIARO

Esempio: l'assistente AI di una scuola

```yaml
apiVersion: kubeai.org/v1
kind: Model
metadata:
  name: assistente-scuola
spec:
  features: [TextGeneration]
  url: hf://Qwen/Qwen2.5-7B-Instruct
  engine: VLLM
  resourceProfile: nvidia-gpu-l4:1
  minReplicas: 0
  maxReplicas: 3
  loadBalancing:
    strategy: PrefixHash
```

Una giornata tipo

07:00	Nessuno lo usa: zero Pod, GPU libera.
08:30	Prima domanda: il modello si accende, la richiesta aspetta in coda.
10:30	Ricreazione, tutti online: fino a 3 repliche.
14:00	Scuola chiusa: si torna a zero.

I dati restano dove decide la scuola.

Altri modelli pronti nel catalogo: charts/models/values.yaml su GitHub

IL CONTO · UN'IPOTESI, NON UN BENCHMARK

Stessa scuola, quasi dieci volte meno GPU

Sempre accese: 3 GPU per 24 ore

72 ore-GPU

Con KubeAI: solo quando servono



7,5 ore-GPU

Il calcolo

1 replica dalle 8:30 alle 14:00, più 2 repliche extra per l'ora della ricreazione.

Perché conta

Meno costi, meno energia. E la GPU libera la usa qualcun altro.

Marco Cristofanilli • Maintainer KubeAI

github.com/kubeai-project/kubeai

DEMO SU GPU · LA RICETTA

La ricetta: una GPU, Kubernetes e KubeAI

```
# 0 · prima: driver NVIDIA, nvidia-smi ok
# 1 · un cluster Kubernetes con un nodo GPU
$ kubectl get nodes
# 2 · GPU Operator: plugin ed etichette GPU
$ helm install gpu-operator nvidia/gpu-operator \
    -n gpu-operator --create-namespace \
    --set driver.enabled=false
# 3 · KubeAI con i profili GPU NVIDIA
$ helm upgrade --install kubeai kubeai/kubeai \
    -n kubeai --create-namespace \
    -f values-nvidia-k8s-device-plugin.yaml
```

qwen-gpu.yaml

```yaml
apiVersion: kubeai.org/v1
kind: Model
metadata:
  name: qwen-gpu
  namespace: kubeai
spec:
  features: [TextGeneration]
  url: hf://Qwen/Qwen2.5-1.5B-Instruct
  engine: VLLM
  resourceProfile: nvidia-gpu-l4:1
  minReplicas: 0
  scaleDownDelaySeconds: 30
```

Il file values NVIDIA è in charts/kubeai su GitHub

DEMO SU GPU · DAL VIVO

Dal vivo: guardate la GPU

1. **La GPU è vuota**

```
$ nvidia-smi
```

2. **Il modello, in YAML**

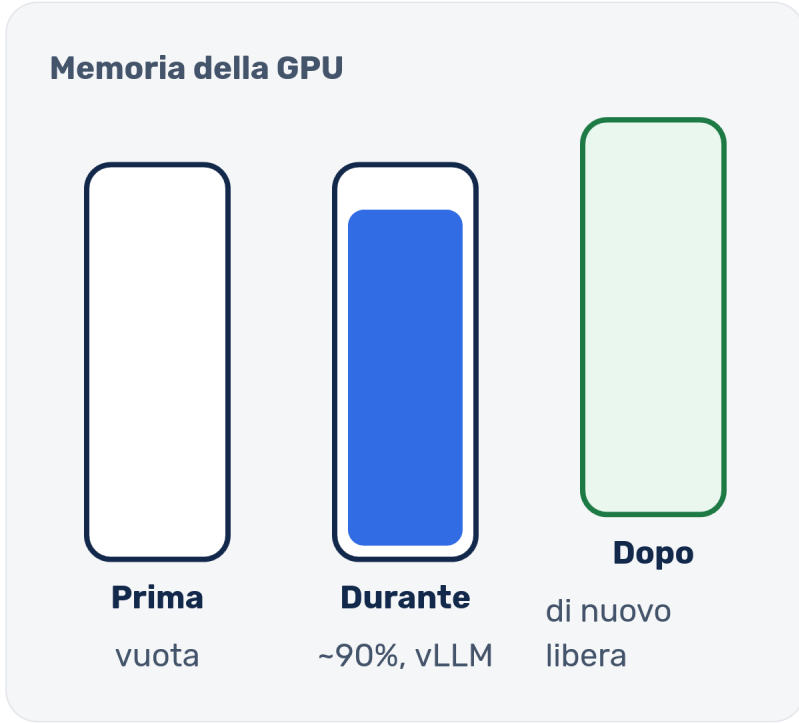
```
$ kubectl apply -f qwen-gpu.yaml
```

3. **Una domanda: il Pod parte**

```
$ curl localhost:8081/openai/v1/chat/completions
```

4. **Silenzio: si torna a zero**

```
$ kubectl get pods -n kubeai --watch
```



FOTOGRAFATE QUESTA SLIDE

Provalo stasera: 5 passi, niente GPU

```
# 1 · un cluster Kubernetes qualsiasi
$ kubectl get nodes
# 2 e 3 · il repository Helm e KubeAI
$ helm repo add kubeai https://www.kubeai.org
$ helm install kubeai kubeai/kubeai --wait --timeout 10m
# 4 · i modelli: kubeai-models.yaml dal README su GitHub
$ helm install kubeai-models kubeai/models -f kubeai-models.yaml
# 5 · la chat su http://localhost:8000
$ kubectl port-forward svc/open-webui 8000:80
```

STATO DEL PROGETTO · OTTOBRE 2026

KubeAI oggi: adottato dalla comunità

2023
Nasce in Google e Substratus

→

2025
I creatori si fermano: non più mantenuto

→

OGGI
Adottato: kubeai-project, tre maintainer

v0.24.0 • 7 ottobre 2026

- Motori SGLang e llama.cpp
- Modelli da immagini OCI
- Inventario AI con k8s-aibom
- Endpoint /v1/systemone

github.com/kubeai-project/kubeai/releases

~1.300
stelle su GitHub

3 su 6
PR della 0.24 da contributori esterni

Lo usano o lo offrono: Telescope • Arcee • Lambda • Vultr • Google Cloud (edge) • Seeweb

Marco Cristofanilli • Maintainer KubeAI

IL VOSTRO PRIMO PASSO

Come contribuire

Usalo e segnala

Una issue fatta bene: cosa hai fatto, cosa ti aspettavi, cosa è successo.

Documentazione

La prima PR può essere piccola: un link vecchio, una guida poco chiara.

Codice in Go

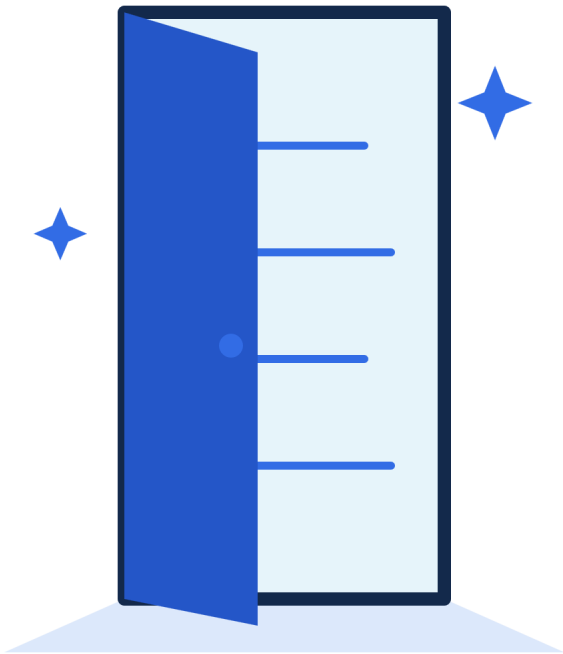
Controller Kubernetes: make test-unit, e kind per i test end-to-end.

Community

Slack, GitHub Discussions e issue aperte. Venite a dire ciao.

`github.com/kubeai-project/kubeai/issues · docs/contributing/development-guide.md · Slack: kubeai-project`

Il prossimo maintainer è in **questa sala.**



Non serve essere esperti per iniziare. Si diventa esperti iniziando.

Marco Cristofanilli • Maintainer KubeAI

github.com/kubeai-project/kubeai

GRAZIE BENEVENTO!

Demo e Domande

github.com/kubeai-project/kubeai

kubeai.org

Marco Cristofanilli

Maintainer KubeAI • github.com/m4oc



Scansiona: il codice di KubeAI