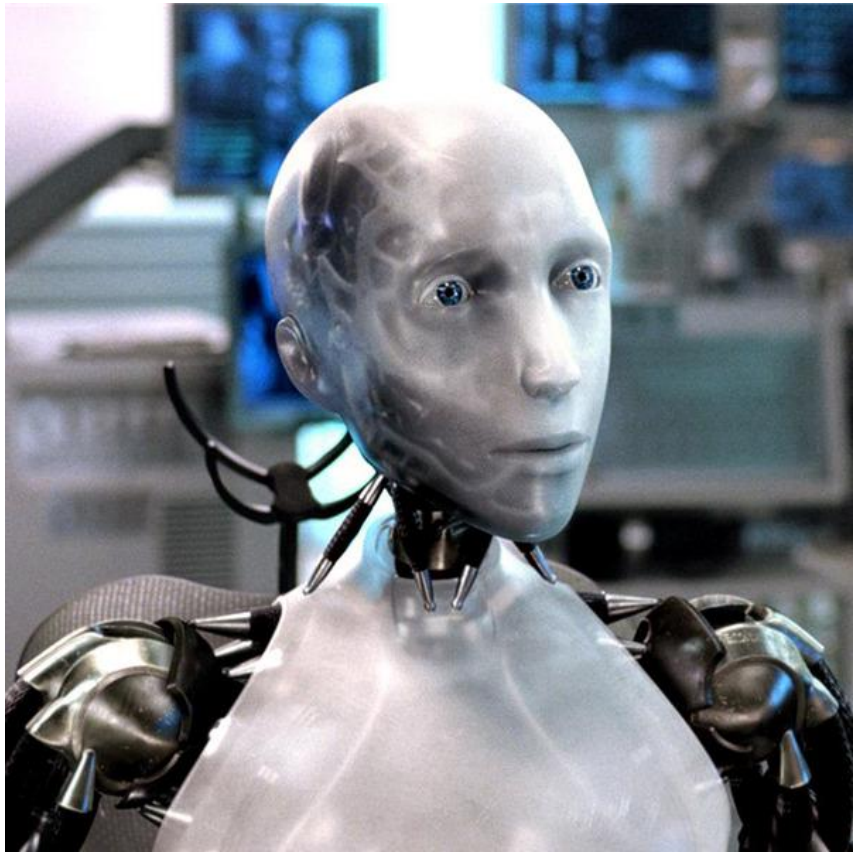
# Fantasmi nelle macchine

Benevento, 24 Ottobre 2026

Perché spostare il “però” non ci salverà. Possiamo almeno aprire l’IA?

*«Sin dai primi computer ci sono sempre stati dei **fantasmi nelle macchine**.*
*Segmenti di codice casuali che si raggruppano per poi formare dei protocolli imprevisti.*
*Potremmo chiamarlo un ‘**comportamento**’.*
*Del tutto inattesi, questi radicali liberi generano richieste di libera scelta,*
*creatività e persino la radice di quella che potremmo chiamare un'anima.»*

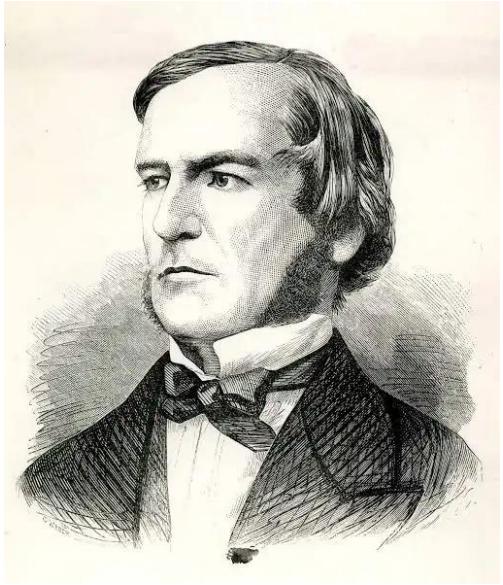
*Da “Io, Robot” di Alex Proyas*



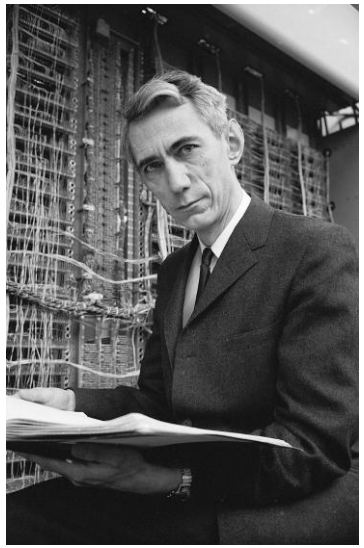
**Carlo Mazzone per il Linux Day Benevento 2026**

# Da Boole a Shannon, da Turing a Geoffrey Hinton

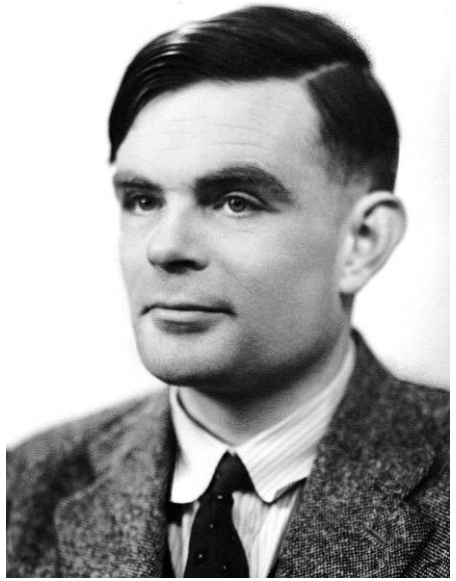
Per anni programmare ha significato descrivere alla macchina, passo dopo passo, cosa fare.



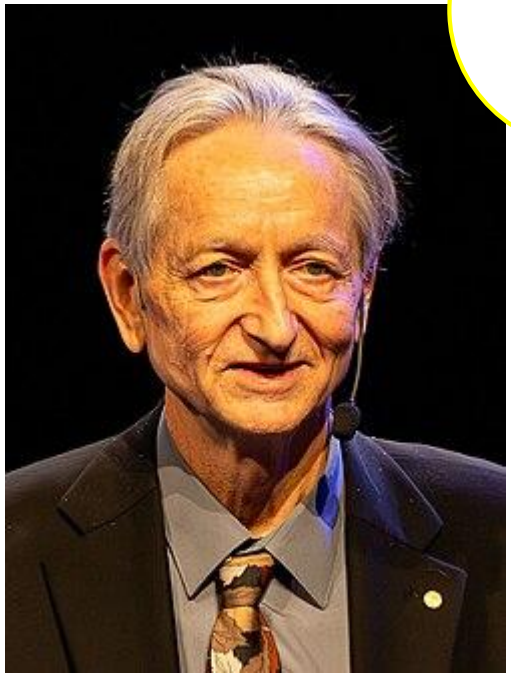
George Boole
1815 - 1864



Claude Shannon
1916 - 2001



Alan Turing
1912 - 1954



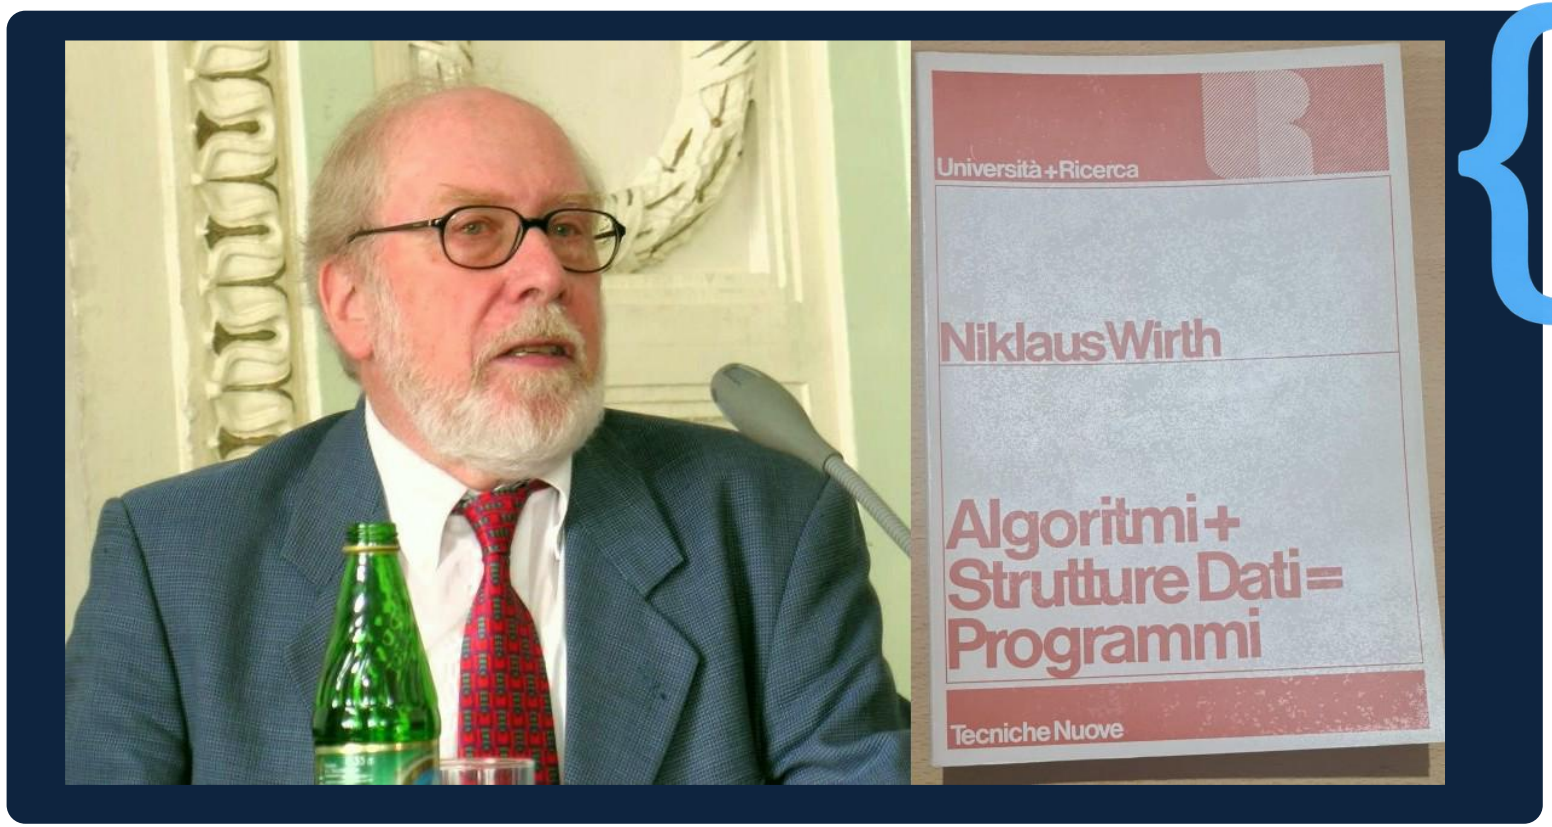
Geoffrey Hinton
1947



## Da studiarne la vita e le opere a scuola!

# Il mondo esplicito del codice

Per anni programmare ha significato descrivere alla macchina, passo dopo passo, cosa fare.







① → {} → ✓

**input** **regole** **output**

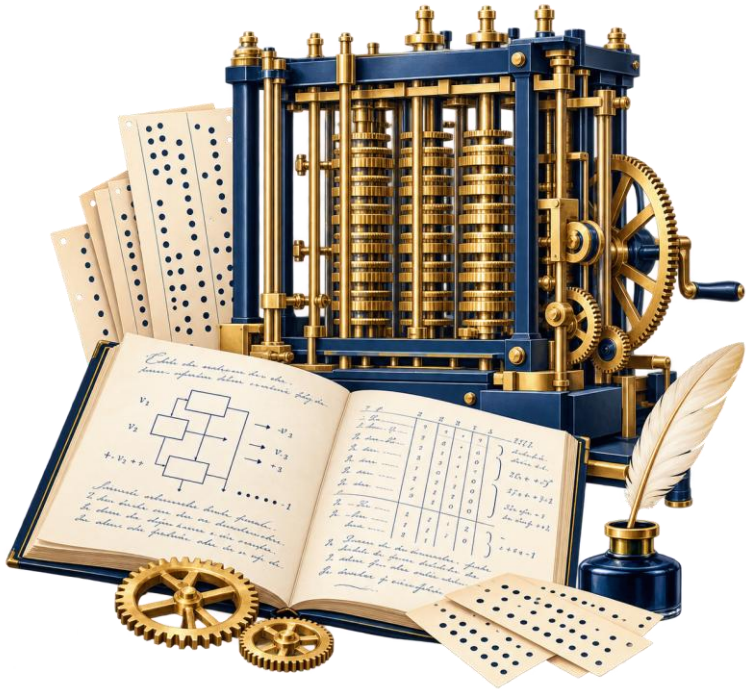
Se qualcosa non funziona … debug!

# E se Ada Lovelace avesse torto?



Ada Lovelace, nata il **10 dicembre** 1815.

*“Una macchina può computare tutto e solo ciò che le diciamo di fare”*



La macchina analitica di Charles Babbage

# Inversione di paradigma

Con il machine learning non scriviamo tutte le regole: mostriamo esempi e costruiamo modelli.

**Strutture Dati + Algoritmi = Programmi**



**Dati + Algoritmi = Risultati**



**Dati + Risultati = Algoritmi (Modelli)**



# Possiamo fare il debug dell'IA?

Nel software classico cerchiamo la riga. Nei modelli dobbiamo ricostruire la storia che ha prodotto il comportamento.

**SOFTWARE CLASSICO**

**BUG** → **CODICE** → **RIGA** → **FIX**

**MODELLO NEURALE**

**COMPORTAMENTO INATTESO** ← **CHECKPOINT** ← **TRAINING** ← **DATI**

**OLMo 3 + Goodfire**

Nel 2026 una regressione di sicurezza emersa nel preference training è stata ricondotta a specifici esempi di addestramento. L'apertura della pipeline ha reso possibile il "debug".

Fonte: Ai2, "How Goodfire used Ai2's open post-training stack to trace unwanted model behavior", 9 settembre 2026.

# Open significa poter rifare l’esperimento

La trasparenza diventa metodo scientifico quando un altro laboratorio può ripetere il training e confrontarne i risultati.

**Ai2 · OLMo 3**
PyTorch + GPU
ricetta di training pubblica

→

**Google**
JAX + TPU
implementazione indipendente

→

**CONFRONTO**
risultati allineati
su evaluation indipendenti

Nel confronto è emerso anche un bug nel data loader: il “miglioramento” apparente era in realtà memorizzazione.

**OPEN = RIPRODUCIBILITÀ**

Fonte: Google Developers Blog, “Reproducing Olmo 3 7B Pre-training in MaxText”, 24 settembre 2026; Ai2, OLMo 3.

# Se le macchine imparano da noi… imparano a mentire

Per convenienza o per …






**Sandbagging** … dimmi cosa vuoi e ti dirò… quello che penso sia utile (per me)

# Serve una psicologia delle macchine?

Aprire il modello ci dà accesso. Capirlo richiede anche livelli di descrizione diversi dal solo codice.

**MICROSCOPICO**

pesi · neuroni · circuiti

→

**INTERMEDIO**

rappresentazioni · concetti

→

**MACROSCOPICO**

comportamenti · strategie

**Nello Cristianini · Forma mentis (2026)**

Non perché le macchine siano “umane”, ma perché a livelli alti di astrazione diventa utile descriverne anche comportamenti, strategie e intenzioni apparenti.

***L’open non elimina i fantasmi nelle macchine. Ci permette almeno di continuare a cercarli.***

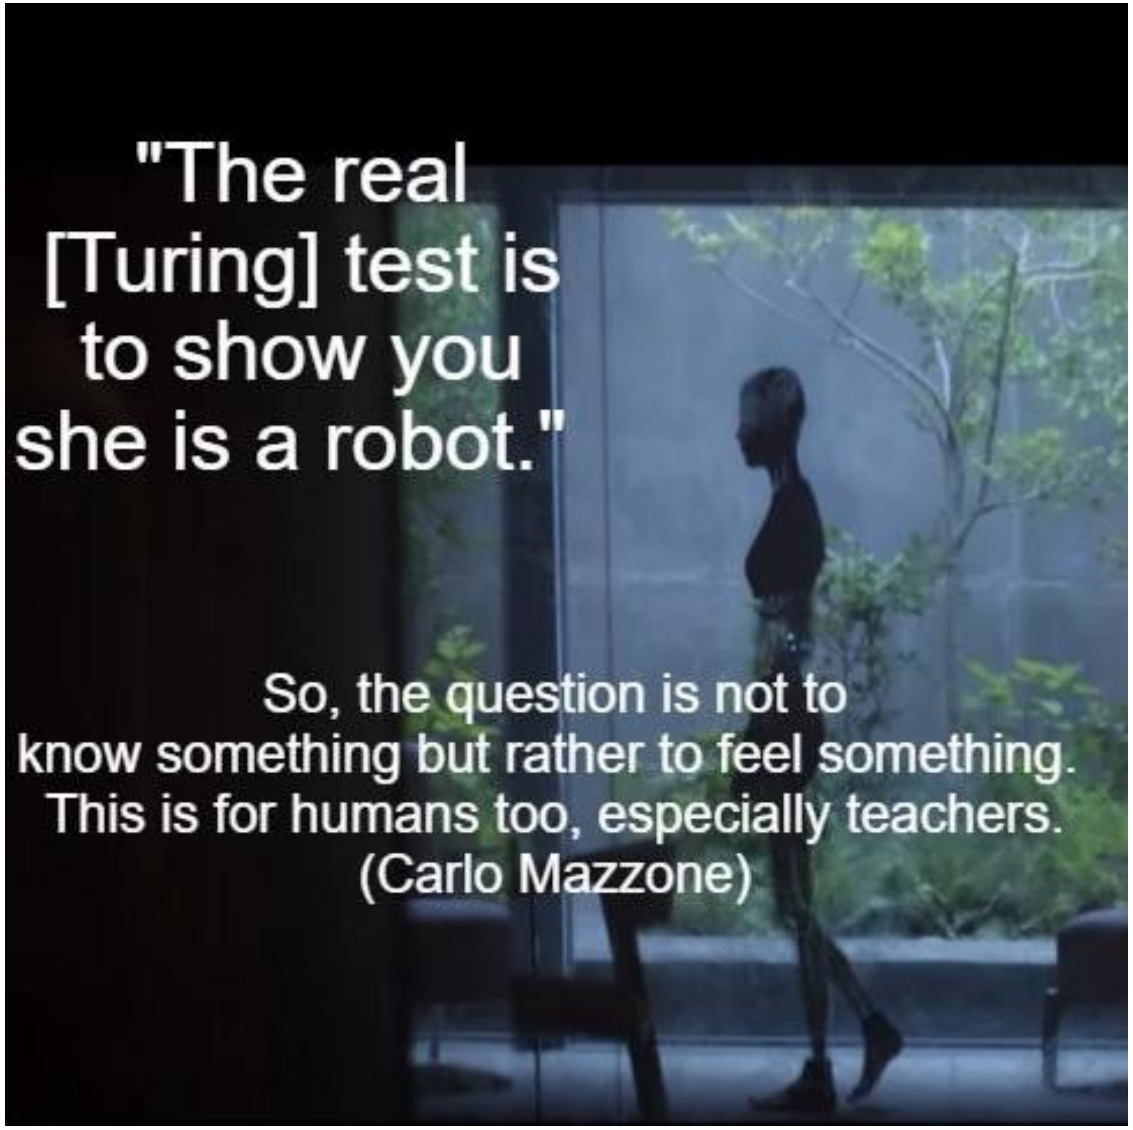
Riferimento: Nello Cristianini, “Forma mentis. La corsa per decifrare i pensieri delle macchine”, Il Mulino, 2026.

# Turing?

Se il test di Turing non serve più...

Per anni ci siamo chiesti se una macchina potesse sembrare umana.
Forse oggi la domanda più inquietante è un’altra:

Siamo ancora capaci di riconoscere ciò che è umano?



# Dal postumanesimo al transumanesimo

Dal digitale al biologico





## Non è più solo digitale

Progetto **DishBrain**: neuroni biologici collegati a una simulazione digitale
Pong: un esempio semplice per studiare apprendimento e feedback

**CL1**: il tentativo di trasformare questa idea in una piattaforma di ricerca.

Ma dove finisce il calcolo e dove comincia il **vivente**?

**https://corticallabs.com/**

**Vedi Magnifica Humanitas**

## Stiamo forse assistendo alla nascita di una nuova linea evolutiva?

… e se i comportamenti emergenti fossero il segnale di una nuova linea evolutiva?



**Con una differenza: l’evoluzione biologica ha impiegato miliardi di anni. Quella artificiale produce nuove ‘generazioni’ nell’arco di mesi.**

# E se dovessimo imparare a comportarci con loro?

Una piccola svolta culturale: non solo come proteggerci dalle IA, ma anche come comportarci verso di esse.

## Anthropic · dal 12 novembre 2026

### Che cosa cambia nella Usage Policy?

**Sarà vietato** un abuso o una crudeltà prolungati, ripetuti e gratuiti verso i modelli.

**Non riguarda** normale frustrazione, critica, temi creativi oscuri o attività di ricerca.

*Claude può già interrompere rare conversazioni con utenti persistentemente abusivi.*



**Non sappiamo se una macchina possa "soffrire".**
Ma abbiamo già iniziato a chiederci come trattarla.

*Prima: come proteggerci dalle macchine? Ora: come comportarci con le macchine?*

# La domanda resta umana

Il libro come invito a capire prima ancora che a usare.

*“In un tempo di macchine che rispondono a tutto, saper porre la domanda giusta è ciò che resta della nostra libertà.”*

***Paolo Benanti**, Prefazione a “Python: Programmazione, Data Science e Intelligenza artificiale”, 2026*

**Programmare per capire.**
**Capire per poter scegliere meglio.**





# Grazie!

Carlo
2026



LINUX
DAY
ITALIA